

Síndrome de Ovario Poliquístico (PCOS)

Contents

1	Introducción	2
2	Aplicación de técnicas de Análisis Multivariado en datos reales	2
3	Tratamiento de los datos	2
3.1	Datos atípicos	2
3.2	Observaciones omitidas	3
3.3	Descripción de variables	3
4	Análisis exploratorio no supervisado	3
4.1	Matriz de correlaciones	3
4.2	PCA	4
4.3	FA	4
4.4	Análisis de escalamiento multidimensional	6
4.5	Análisis de Correspondencias Múltiples (MCA)	6
5	Modelos de predicción	7
5.1	Análisis de Discriminantes (DA)	7
5.2	Árbol de decisión	8
5.3	Random Forest	9
6	Conclusiones	11

1 Introducción

El síndrome de ovario poliquístico (SOP) es uno de los trastornos hormonales más frecuentes en mujeres en edad reproductiva y, al mismo tiempo, uno de los más complejos de diagnosticar y tratar. Desde que fue descrito por primera vez en 1935, la comprensión de esta enfermedad ha evolucionado considerablemente.

A partir de 2026, el SOP comenzará a denominarse síndrome ovárico metabólico poliendocrino (SOMP). El cambio de nombre surgió de la necesidad de reflejar mejor la naturaleza de la enfermedad y evitar que su atención se limite únicamente al ámbito ginecológico. El término **“poliendocrino”** destaca la participación de distintos sistemas hormonales en el desarrollo del síndrome. Por su parte, el término **“metabólico”** reconoce su estrecha relación con la resistencia a la insulina y otros factores de riesgo cardiometabólico. Finalmente, **“ovárico”** mantiene la referencia a las alteraciones en la función de los ovarios, aunque sin considerarlas el único aspecto que define la enfermedad. Normalmente, el síndrome se ha diagnosticado cuando una mujer presenta algunas de las siguientes características: exceso de andrógenos, hormonas que pueden provocar la aparición de rasgos masculinos; resistencia a la insulina; infertilidad; alteraciones en los ciclos menstruales y cambios estructurales en los ovarios, como la presencia de múltiples quistes.

2 Aplicación de técnicas de Análisis Multivariado en datos reales

Se proporcionó un conjunto de datos que contiene parámetros físicos y clínicos utilizados para identificar el SOP, así como información relacionada con la fertilidad. Dichos datos fueron recopilados en 10 hospitales diferentes de Kerala, India y conforman una base con 541 observaciones y 40 variables. De estas, 11 corresponden a variables categóricas y 29 a variables numéricas.

A partir de la información proporcionada, se aplicarán distintas técnicas estadísticas propias del análisis multivariado con la intención de encontrar información relevante sobre este padecimiento en el ámbito estadístico para posteriormente desarrollar un modelo predictivo.

3 Tratamiento de los datos

Ya que contábamos con variables que hacían referencia al índice de masa corporal, la proporción entre las hormonas FSH y LH, y otra variable respecto a la relación cintura-cadera (variable “Waist Ratio”), se decidió eliminar las variables: “Weight (Kg)”, “Height(Cm)”, “FSH(mIU/mL)”, “LH(mIU/mL)”, “Hip(inch)” y “Waist(inch)”.

Por otro lado, la variable “No. of abortions” presenta una alta concentración de observaciones iguales a 0. Por esta razón, se decidió transformarla en una variable categórica que indica si hay de antecedentes de aborto en la paciente, de esta forma simplificamos su interpretación y reducimos la influencia de valores poco frecuentes.

Con base en la opinión de especialistas en el área, se decidió trabajar con el número total de folículos en lugar de considerar por separado el número de folículos presentes en cada ovario. Por esta razón, se eliminaron las variables “Follicle No. (L)” y “Follicle No. (R)”, y se construyó la variable “Total_Follicle”, que representa la suma de ambas variables.

3.1 Datos atípicos

Posteriormente, se analizó la estructura de los datos y, mediante el summary, se pudo detectar la presencia de outliers. Para determinar si estos outliers podían considerarse válidos o no en nuestro análisis, se decidió corroborar la información revisando literatura médica. Los outliers detectados fueron los siguientes:

- $FSH/LH = 1372.826$
- $Vit\ D3\ (ng/mL) = 6014.86$
- $Vit\ D3\ (ng/mL) = 5418.6$

Dado que estas cifras distan considerablemente de valores clínicos reales, incluso en casos extremos, estos outliers pasan a considerarse errores de medición y se omiten del análisis. Lo anterior puede apreciarse visualmente mediante los siguientes boxplots:

Detección de Valores Atípicos



3.2 Observaciones omitidas

Se detectó la presencia de 3 valores faltantes en el conjunto de datos. Dada la reducida cantidad de NAs encontrados, se optó por omitir las observaciones asociadas a dichos datos faltantes, ya que representaban menos del 3% del total de los datos. Por otro lado, la variable “Cycle (R/I)” corresponde a una variable categórica con dos niveles. Sin embargo, se identificó una observación con un nivel adicional no esperado. En consecuencia, esta observación fue excluida del conjunto de datos para garantizar la consistencia de la variable.

3.3 Descripción de variables

Después de la limpieza de datos, la base sobre la que trabajará quedó conformada por 33 variables, de las cuales 12 son categóricas (incluyendo la variable objetivo) y 21 numéricas. Se describen brevemente a continuación:

Variables antropométricas y demográficas: Age_yrs (edad), Marriage.Status.Yrs (años matrimonio), BMI (IMC), Waist_Hip.Ratio (índice cintura-cadera), Blood.Group (grupo sanguíneo).

Signos vitales: Pulse.rate.bpm (frecuencia cardíaca), RR_breaths.min (frecuencia respiratoria), BP_Systolic_mmHg (presión sistólica), BP_Diastolic_mmHg (presión diastólica).

Variables hormonales: FSH.LH (relación FSH/LH), TSH_mIU.L (TSH), AMH_ng.mL (hormona antimülleriana), PRL_ng.mL (prolactina), PRG_ng.mL (progesterona).

Variables metabólicas: Hb_g.dL (hemoglobina), Vit.D3_ng.mL (vitamina D3), RBS_mg.dL (glucosa).

Variables ginecológicas: Cycle.length.days (duración sangrado), Total_Follicle (total folículos), Avg_F_size_L_mm (tamaño prom. de folículos en ovario izq), Avg_F_size_R_mm (tamaño prom. de folículos en ovario der), Endometrium_mm (grosor del endometrio), Cyclic.R.I (regularidad ciclo), Pregnant.Y.N (embarazo).

Variables clínicas: PCOS.Y.N (diagnóstico SOP), Weight.gain.Y.N (aumento peso), hair.growth.Y.N (hirsutismo), Skin.darkening.Y.N (oscurecimiento piel), Hair.loss.Y.N (caída cabello), Pimples.Y.N (acné).

Estilo de vida: Fast.food.Y.N (comida rápida), Reg.Exercise.Y.N (ejercicio).

4 Análisis exploratorio no supervisado

4.1 Matriz de correlaciones


Por medio de la matriz de correlaciones (consultar chunk `correlaciones`) se puede decir que hay una gran ausencia de correlaciones significativas entre las distintas variables numéricas, puesto que la mayoría de las asociaciones son muy cercanas a 0.

Las correlaciones más destacables son positivas y se presentan entre la edad y los años de casada de la paciente, entre la frecuencia cardíaca y la frecuencia respiratoria, así como entre el tamaño promedio de los folículos del ovario izquierdo y derecho. Esta información es bastante consistente desde el punto de vista clínico, pues se trata de pares de variables que tienden a aumentar en conjunto.

Dada la estructura antes descrita por la matriz de correlaciones, resulta poco plausible pensar en que existan grupos de variables altamente relacionadas. Sin embargo, para evaluar si realmente existen estructuras latentes o patrones de agrupamiento que permitan representar los datos en pocas dimensiones, se emplearán diversas técnicas de reducción de dimensión y visualización.

4.2 PCA

Después de obtener la matriz de correlaciones, empezaremos observando si es que se puede reducir la dimensión de nuestra base de datos mediante PCA como método exploratorio no supervisado.




A partir del gráfico de contribuciones y la gráfica de barras, se puede notar que PCA presenta una capacidad limitada para resumir la información pues la cantidad de variabilidad que explica cada componente principal es poca, reuniendo apenas el 70% de variabilidad con 12 dimensiones. Por otro lado, se destaca que las variables que más contribuyen al PCA son: “Age”, “Marriage Status”, Avg. F size (L)/(R), “FSH/LH”, entre otras. Las variables antes mencionadas aportan mucha información para las primeras dos dimensiones del pca y son consistentes con lo que mencionábamos en la matriz de correlaciones

4.3 FA

Dado que PCA se basa únicamente en la maximización de varianza explicada, se optó por también explorar el uso de FA con dos factores, compararemos con pca y tendremos una conclusión de si usar pca, fa o ninguna de las dos.


Parallel analysis suggests that the number of factors = 5 and the number of components = NA



Viendo el gráfico de eigenvectores, gracias a la prueba de Barlett podemos elegir 4 factores para observar si es que nuestra base tiene algún tipo de estructura o patrón. Sin embargo, la interpretabilidad del análisis se pierde nuevamente, por lo que no resulta conveniente trabajar con análisis factorial ya que no podemos concluir asociaciones entre variables para poder clasificar patrones.

Pudimos notar que con 4 factores solo hay 8 variables con relación importante con nuestros factores (consultar chunk: `cargas_FA`). Dentro de las que mas estan relacionadas con el primer factor es Age y Marriage status, que se puede interpretar como un factor de tiempo. Sin embargo, las demás variables prácticamente no tienen relación alguna con alguno de los factores. Antes de sacar algún tipo de conclusión veamos que es lo que pasa con el screeplot.

Proyección de Pacientes en Factores Rotados (FA)




Para el screeplot usamos dos factores ya que es mucho mas fácil visualizar los datos con dos dimensiones. En el screeplot de los factores podemos ver que no hay una distinción clara entre las personas que tienen PCOS (puntos rojos) y los que no (puntos azules). Hay traslape entre las personas que tienen PCOS y las que no, por lo que no podemos encontrar un patrón en nuestros datos numéricos. Por esto decidimos no usar FA. Es probable que utilizemos demasiadas dimensiones si quisiéramos hacer pca y no encontrar algún patrón si usamos 2 o varios fa por lo que no usaremos ninguno de los métodos anteriores.

4.4 Análisis de escalamiento multidimensional

Para el escalamiento multidimensional utilizamos 3 tipos de distancias; la euclidiana, la manhattan y la gower. Se alcanza a apreciar que la distancia que mejor caracteriza nuestra base es la gower, esto por que hay mucho menos traslape en comparación a las distancias anteriores, de igual manera la distancia gower funciona mejor ya que se debe a que la distancia gower acepta ambos tipos de dato, las numéricas y las categóricas. Sin embargo, en este escalamiento no es perfecto y por ese motivo seguiremos explorando mas técnicas de análisis exploratorio.

Comparación de Métricas de Distancia para MDS

Análisis de Escalamiento Multidimensional




4.5 Análisis de Correspondencias Múltiples (MCA)

Anteriormente se hizo uso de PCA y FA, sin embargo, ambos son métodos que consideran únicamente variables numéricas. A causa de que una parte importante de la información que se dispone corresponde a variables categóricas se hace uso de MCA, una técnica multivariada meramente descriptiva, con la intención de encontrar asociaciones entre variables categóricas que no son capturadas mediante las técnicas anteriores.

Debido a la gran cantidad de variables categóricas utilizadas en este análisis (y a sus múltiples niveles), se necesitan muchas dimensiones para poder explicar una alta proporción de la variabilidad. Por esta razón, se utilizan las dos primeras dimensiones para representar gráficamente los resultados, aunque nuestra atención se centra en la primera dimensión, ya que la segunda resulta difícil de interpretar y la proporción de inercia explicada es menor.

Asociaciones entre categorías categóricas (MCA)



Usando como medida de correlación el $\cos^2$ en la proyección de las pacientes (consultar chunk `mca`) se muestra que las observaciones con mayor contribución individual a la construcción del plano obtenido tienden a distribuirse de forma

diferenciada, ya que las pacientes con SOP se concentran principalmente hacia la derecha del gráfico (ej; obs 460,140,468), mientras que aquellas sin SOP se ubican mayormente hacia la izquierda (ej; obs 27,50,168).

De igual forma, a partir de los gráficos de asociaciones entre categorías, se observa que aunque la variable objetivo no haya sido incluida en el MCA, la primera dimensión muestra que las categorías asociadas a la ganancia de peso, el crecimiento de vello en zonas andrógenas, los hábitos alimenticios, el oscurecimiento de la piel, la presencia de acné y la pérdida de cabello pueden desempeñar un papel importante en la diferenciación entre pacientes con y sin SOP. Además, esta información sobre la separación es consistente con las contribuciones de las categorías a la primera dimensión (consultar chunk mca3)

5 Modelos de predicción

Por medio del análisis exploratorio realizado, pudimos apreciar que las técnicas basadas únicamente en variables numéricas presentaban dificultades para resumir la información en pocas dimensiones. En contraste, la técnica para variables categóricas (MCA) mostró que este tipo de variables se encuentran asociadas con la presencia del SOP y contribuyen a diferenciar a las pacientes con y sin la afección. Estos resultados sugieren que la información necesaria para diagnosticar a futuras pacientes con SOP se encuentra distribuida entre ambos tipos de variables, por lo que resulta conveniente emplear modelos capaces de integrar simultáneamente información numérica y categórica.

5.1 Análisis de Discriminantes (DA)

Si bien los datos poseen cierta estructura que dificultaría únicamente trabajar con variables continuas, así como que no cumplen estrictamente los supuestos de normalidad multivariada ni de igualdad entre matrices de covarianzas (consultar chunk DANormTests), se decidió probar con ajustes clásicos multivariados como LDA (Análisis Discriminante Lineal) y QDA (Análisis Discriminante Cuadrático) a manera de modelos predictivos de referencia para posteriormente plantear un modelo más complejo. Para ello, se realizó una partición de los datos utilizando un 80% de las observaciones para entrenamiento y el 20% restante para prueba.

Table 1: Métricas de desempeño para los modelos LDA y QDA


Modelo	Sensibilidad	Especificidad	Accuracy
LDA	70.0%	90.8%	84.9%
QDA	80.0%	53.9%	61.3%

Mediante el ajuste de LDA se clasificó correctamente al 84.9% de las pacientes, identificando adecuadamente al 64.5% de aquellas con SOP y al 90.8% de aquellas sin la afección. Estos resultados muestran una capacidad de clasificación razonable, aunque todavía existe una proporción importante de pacientes que no son identificadas correctamente.

Por su parte, QDA logró detectar una mayor proporción de pacientes con SOP, con aproximadamente diez puntos porcentuales por encima de LDA. Sin embargo, esta mejora se obtuvo a costa de una disminución considerable en la especificidad, lo que provocó un incremento importante en las clasificaciones erróneas de pacientes sin SOP y redujo el accuracy global al 61.3%.

Bajo el objetivo de evaluar la capacidad predictiva, LDA mostró resultados superiores a los obtenidos por QDA. No obstante, estos resultados deben interpretarse con cautela debido al incumplimiento de los supuestos del modelo.


Asimismo, la distribución del discriminante muestra un importante traslape entre las agrupaciones, lo que evidencia la dificultad para separar linealmente a las pacientes con y sin SOP. Esta situación ayuda a explicar por qué, a pesar de su buen desempeño global, el modelo tiene dificultades para identificar correctamente una parte de las pacientes con la afección.



5.2 Árbol de decisión

Para este punto, el probar con un modelo que nos permita utilizar tanto variables categóricas como variables numéricas resulta en el camino más pertinente para desarrollar un modelo predictivo eficiente, es por esto que hemos decidimos implementar un modelo de arbol de decisión ya que este acepta ambos tipo de variables

Árbol de Decisión Representativo (profundidad=4)



Una cualidad importante en cualquier método estadístico es su interpretabilidad; dicha característica constituye una de las principales fortalezas de los árboles de decisión. Además, estos modelos utilizan la impureza de Gini para seleccionar tanto las variables como los puntos de corte que mejor separan las clases basado en la cantidad de variables candidatas que especifiquemos. Esto representa una ventaja adicional, ya que no sólo facilitan la interpretación de los resultados, sino que también permiten identificar variables relevantes y controlar el grado de complejidad del modelo.

Observando el árbol anterior, podemos destacar lo siguiente. Lo primero, y más notorio, son los colores de cada nodo; en este caso, el color azul indica una alta probabilidad de tener el síndrome, mientras que los bloques en gris claro indican una alta probabilidad de no tener la afección. Otra cosa a destacar es que podemos ver que la primera variable que usó el modelo para que el árbol haga su primer split es el número total de folículos, observando si la persona en cuestión tiene un número total de folículos mayor o igual a 17. Después, dependiendo de la rama en donde estemos, el modelo hará un segundo split: en caso de que la paciente tenga menos de 17 folículos totales, ahora se observará si hubo crecimiento de vello en zonas andróginas; en el caso de que se observe que haya tenido 17 o más folículos totales, se observa si consume comida rápida frecuentemente, y así sucesivamente.

La forma de interpretar este árbol de profundidad 4 se puede ejemplificar de las siguientes maneras:


Supongamos que llega una paciente con menos de 17 folículos totales y sin crecimiento excesivo de vello en zonas andrógenas. Con estas características, el árbol probablemente la clasificaría dentro del grupo de pacientes sin SOP. Ahora supongamos que llega una paciente con más de 17 folículos totales que además consume comida rápida frecuentemente. En este caso, es muy probable que el árbol la clasifique dentro del grupo de pacientes con SOP.


Entre las variables que podemos encontrar en este árbol, se encuentran: “Total_Follicules” (la cual se más de una vez en este árbol), “Fast food (Y/N)”, “Weight gain(Y/N)”, “Hair growth(Y/N)”, “Pimples(Y/N)”, sin estas variables de nuestra base, nuestro modelo sería incapaz de distinguir a las personas con la afección de las personas que no tienen el síndrome, en otras palabras, son las variables más importantes para este modelo.

5.3 Random Forest


Aunque el anterior árbol resulta útil para entender el proceso de clasificación, la decisión final del modelo no depende de un único árbol. Por ello, Random Forest construye cientos de árboles utilizando distintas muestras de los datos y combina sus predicciones usando la moda (como si se tratara de una votación). Así, los errores de algunos árboles pueden ser compensados por los demás, produciendo predicciones más estables y precisas.

Tras ajustar un bosque de 500 árboles y considerar 5 variables candidatas en cada división, el modelo logró clasificar correctamente al 94.3% de las pacientes del conjunto de prueba. Asimismo, identificó correctamente el 86.7% de los casos con SOP y clasificó adecuadamente al 97.4% de las pacientes sin la afección. Este resultado es particularmente interesante porque supera ligeramente las métricas observadas durante el entrenamiento, situación que puede explicarse por el proceso de partición del train y el test.






En general podríamos decir que el ajuste obtenido mediante Random Forest es bastante sólido. Dicha condición se ve reforzada por el alto valor obtenido en AUC (área bajo la curva) de 0.97, así como el extraordinario comportamiento de la curva ROC la cual rápidamente se aproxima a 1. Este conjunto de características reflejan la excelente capacidad para distinguir entre pacientes con y sin SOP que posee el modelo.



Por último, para identificar qué variables contribuyen al desempeño del bosque, se utilizó la métrica Mean Decrease Accuracy (MDA). Gracias a esta métrica pudimos observar que “Total_Follicle” predomina en el aporte para distinguir entre clases. Además, podemos ver que las variables categóricas realmente presentan una contribución importante para realizar predicciones donde se destacan aquellas que hacen referencia al crecimiento del vello en zonas andrógenas, la ganancia del peso, el oscurecimiento de la piel y la regularidad del ciclo entre otras (ver el chunk `variablesRelevantes`).

10 Variables Más Importantes



6 Conclusiones

A lo largo de este análisis, la estructura del conjunto de datos nos fue orientando a probar distintos métodos multivariados que nos permitieron desarrollar modelos supervisados predictivos. Dada la importancia que tenía considerar tanto variables numéricas como categóricas, el uso de un modelo tan robusto como Random Forest nos permite realizar predicciones sobre diagnósticos bastante sólidos, los cuales pueden ayudar en la toma de decisiones.

Si bien es cierto que, a primera vista, Random Forest puede parecer un modelo complejo y poco interpretable, comprender el funcionamiento de un árbol de decisión permite entender la lógica general detrás de sus predicciones. Asimismo, si consideramos su capacidad para seleccionar variables, resulta fácil identificar cuáles son los factores que más contribuyen al proceso de clasificación, convirtiendo a Random Forest en un modelo no sólo preciso, sino también informativo.

Es importante destacar que, aunque Random Forest destacó por su increíble capacidad para clasificar y predecir, por encima de modelos como LDA y QDA, también es bastante consistente con el nuevo enfoque sobre el cual ahora se aborda el síndrome de ovario poliquístico, pues aunque el número de folículos totales sí tiene un gran impacto sobre el modelo, al considerar también características descritas en las variables categóricas no sólo estamos clasificando bien, sino que tampoco dejamos de lado la naturaleza poliendocrina, metabólica y ovárica de esta afección.

En cuanto al trabajo en general, se pudo observar que las técnicas no supervisadas iniciales (como PCA y FA) evidenciaron las limitaciones de trabajar únicamente con variables numéricas, debido al alto traslape entre grupos y la baja varianza explicada en pocas dimensiones. Sin embargo, el análisis de correspondencias múltiples (MCA) y el escalamiento multidimensional con distancia de gower separaron de mejor forma las variables. Aunque esto no fue suficiente para el análisis, nos permitió explorar un algoritmo de aprendizaje automático capaz de integrar ambos tipos de datos.

Un punto importante en el modelo de Random Forest es la ausencia de sobreajuste, esto se corrobora al comparar las métricas de rendimiento mencionadas anteriormente. El hecho de que el desempeño del modelo en el conjunto de prueba sea igual o incluso ligeramente superior al observado durante el entrenamiento nos dice que el algoritmo ha aprendido patrones generalizables de la enfermedad, y no simplemente ha memorizado el ruido o las particularidades de los datos de entrenamiento. Esto garantiza la confiabilidad del modelo para ser aplicado en futuros casos clínicos.